

# Cadenas de Markov

Calixtro Ames, Cynthia Lizeth  
ccalixtro@uni.pe  
Escuela de Ciencia de la Computación  
Universidad Nacional de Ingeniería

Huamaní Inga, Alex Raúl  
ahuamanii@uni.pe  
Escuela de Matemática  
Universidad Nacional de Ingeniería

24 de junio de 2018

## Resumen

Aquí va el resumen

## 1. Introducción

### 1.1. Conceptos previos

#### 1.1.1. Procesos Estocásticos

Un proceso estocástico se puede definir equivalentemente de dos formas diferentes:

1. Como un conjunto de realizaciones temporales y un índice aleatorio que selecciona una de ellas.
2. Como un conjunto de variables aleatorias  $X_t$  indexadas por un índice  $t$ , dado que  $t \in T$  con  $T \subseteq \mathbb{R}$ .

Un proceso se dice de **tiempo continuo** si  $T$  es un intervalo (usualmente este intervalo se toma como  $[0, \infty)$ ) o de **tiempo discreto** si  $T$  es un conjunto numerable (solamente puede asumir determinados valores, usualmente se toma  $T \subseteq \mathbb{N}$ ). De donde el conjunto  $T$  será llamado **espacio parametral** en donde las variables aleatorias toman valores en un conjunto  $S$  llamado **espacio de estados**

#### 1.1.2. Trayectoria de un proceso

Una *trayectoria* de un proceso estocástico  $x_t : t \in T$  es una función

$$t \mapsto X_t(w)$$

para cada  $w \in \omega$ . Existen distintos tipos de procesos estocásticos. Éstos se obtienen al considerar

- Distintos espacios parametrales.
- Distintos espacios de estado.
- Distintas características de la trayectorias.
- Distintas relaciones de dependencia estocástica entre las variables aleatorias que conforman el proceso.

#### 1.1.3. Algunos ejemplos de procesos

##### ■ Proceso de ensayos independientes

supongamos que el espacio parametral  $T = 1, 2, \dots$  es el conjunto de números naturales y  $S \subseteq \mathbb{R}$ , cuando las variables aleatorias  $(X_1, X_2, \dots)$  son independientes se dice que este es un proceso estocástico de ensayos independientes, recordar que una colección infinita de variables es independiente si toda subcolección finita lo es”

- **Procesos de Markov**

El proceso  $X_t : t = 0, 1, \dots$  es donde  $X_t \in S$  es discreto es un **proceso de Markov** si para cada  $x_0, x_1, \dots, x_{n+1} \in S$  se cumple la siguiente propiedad

$$P(X_{n+1} = x_{n+1} | X_0 = x_0, \dots, X_n = x_n) = P(X_{n+1} = x_{n+1} | X_n = x_n)$$

Es decir la historia del proceso hasta el tiempo  $n-1$  es irrelevante cuando se conoce el estado del proceso al tiempo  $n$  a esta identidad se le conoce con el nombre de **propiedad de Markov** y es un buen ejemplo del tipo de dependencia estocástica que puede existir entre las variables de un proceso en este caso las variables aleatorias son discretas y al proceso lo llamaremos **Cadenas de Markov** en este pequeño artículo nos centraremos en esto.

- **Procesos con incrementos independientes**

el proceso  $X_t : t \geq 0$  tiene **incrementos independientes** si las variables aleatorias

$$X_{t_1}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

son independientes para cualesquiera tiempos  $0 \leq t_1 < t_2 < \dots < t_n$ .

- **Procesos estacionarios**

El proceso  $X_t : t \geq 0$  es **estacionario** en el sentido estricto si para cualesquiera  $t_1, \dots, t_n, h \geq 0$

$$(X_{t_1}, \dots, X_{t_n}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_n+h})$$

de donde el vector aleatorio del lado derecho tiene la misma distribución que el vector aleatorio del lado izquierdo. Esto significa que el vector aleatorio del lado izquierdo se puede trasladar en el tiempo como indica el vector del lado derecho sin que cambie su distribución de probabilidad.

- **Procesos con incrementos estacionarios**

El proceso  $X_t : t \geq 0$  tiene **incrementos estacionarios** si para cualesquiera  $0 \leq s < t; h \geq 0$

$$X_t - X_s \stackrel{d}{=} X_{t+h} - X_{s+h}$$

- **Martingalas**

El proceso  $X_t : t = 0, 1, \dots$  es una **Martingala** si

$$E(X_{n+1} | X_0 = x_0, \dots, X_n = x_n) = x_n$$

pero en realidad hay otras condiciones técnicas que se piden a un proceso para que sea un martingala.

- **Procesos de Lévy**

El proceso  $X_t : t \geq 0$  es un **proceso de Lévy** si sus incrementos son:

- Independientes
- Estacionarios

- **Procesos Gaussianos**

El proceso  $X_t : t \geq 0$  es un **proceso gaussiano** si para cualesquiera tiempos  $t_1, \dots, t_n$

$$(X_{t_1}, \dots, X_{t_n}) \sim \text{Normal multivariada}$$

Observaciones. No debe pensarse que estas características de los procesos son excluyentes unas de otras, por ejemplo existen varios procesos estocásticos que cumplen varias de estas propiedades al mismo tiempo, por ejemplo el movimiento Browniano es un proceso estocástico importante es un proceso **gausiano** con **incrementos independientes** y **estacionarios** por lo tanto es un proceso de **Lévy**, puede además demostrarse que es una **Martingala** y que cumple la **propiedad de Markov**

## 1.2. Conceptos y simulación

### 1.2.1. Cadenas de Markov

#### Definición 1. Espacio de estados

Definimos el *espacio de estados* como el conjunto formado por todos los posibles valores que puede tomar  $X_n$  donde el índice  $n$  representa la evolución del proceso en el *tiempo*. Para una cadena de Markov tanto el *espacio de estados* como el *tiempo* pueden ser discreto o continuo.

#### Definición 2. Cadena de Markov

Una cadena de Markov es una secuencia de variables aleatorias  $X_0, X_1, X_2, \dots$  que toman valores en el *espacio de estados*  $\{1, 2, \dots, M\}$  si para todo  $n \geq 0$  se cumple la propiedad de Markov. Donde  $P(X_{n+1} = x_{n+1} | X_n = x_n)$  se denomina probabilidad de transición desde el estado  $i$  hacia el estado  $j$ . Como esta probabilidad no depende de el valor de  $n$  se dice que el tiempo es *homogeneo*.

#### Definición 3. Matriz de transición

Sean  $X_0, X_1, X_2, \dots$  una cadena de Markov con espacio de estados  $\{1, 2, \dots, M\}$  y sea

$$p_{ij} = P(X_{n+1} = j | X_n = i)$$

la probabilidad de transición del estado  $i$  al estado  $j$ . Entonces, a la matriz  $M \times M$ ,  $P = \{p_{ij}\}$  se le denomina *matriz de transición* de la cadena. Además, la suma de los valores por fila es igual a 1.

**Definición 4. Propabilidad de transición en n pasos** La probabilidad de transición en  $n$  pasos de  $i$  hacia  $j$  es la probabilidad de ir de  $i$  hacia  $j$  en  $n$  pasos. Denotamos esto como  $p_{ij}^{(n)}$  y se define de la siguiente manera:

$$p_{ij}^{(n)} = P(X_n = j | X_0 = i)$$

y se cumple que  $p_{ij}^{(n)}$  es el elemento de subíndices  $(i, j)$  de la matriz  $P^n$

#### Definición 5. Distribución Marginal de $X_n$

Sea el vector fila  $q = (q_1, \dots, q_M)$  con  $q_i = P(X_0 = i)$  entonces la *distribución marginal* de  $X_n$  está dada por el vector  $qP^n$ . Es decir, el  $j$ -ésimo componente del vector  $qP^n$  es  $P(X_n = j)$

### 1.2.2. Cadena de Markov Irreducible

Se dice que una cadena de Markov con matriz de transición  $P$  es *irreducible* si para dos estados  $i$  y  $j$  cualesquiera existe un entero positivo  $n$  tal que el elemento de índices  $(i, j)$  en la matriz  $P^n$  es positivo. Es decir, es posible ir de  $i$  a  $j$  en un número finito de pasos. En caso contrario se dirá que la cadena de Markov es *reducible*.

### 1.2.3. Cadena de Markov Periódica

#### Definición 6. Periodo de un estado

Se define el periodo  $d_i$  de el estado  $i$  como

$$d_i = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}$$

Esto es, el *gcd* (*máximo común divisor*) del posible número de pasos que puede tomar para regresar al mismo estado, en este caso, al estado  $i$ . Cuando un estado tiene periodo igual a 1 entonces se dirá que es *aperiódico*, en caso contrario, se le llamará *periódico*.

Una cadena de Markov es llamada *aperiódica* cuando todos sus estados son aperiódicos. En caso contrario, se le denomina *periódica*.

### 1.2.4. Distribuciones estacionarias

Un vector fila  $\pi = (\pi_1, \dots, \pi_M)$  con  $\pi_i \geq 0$  and  $\sum_i \pi_i = 1$  es una *distribución estacionaria* para una cadena de Markov con *matriz de transición*  $P$  si

$$\pi P = \pi$$

Si  $\pi$  es la distribución de  $X_0$ , esto es si  $\pi_i = P(X_0 = i)$ , entonces  $\pi P$  vendría a ser la distribución marginal de  $X_1$ . Esto significa que, si  $X_0$  tiene distribución  $\pi$ , entonces  $X_1$  también tendrá una distribución  $\pi$ .

Si  $X_2$  tiene una distribución  $\pi$  entonces  $X_3$  también la tendrá y así sucesivamente. Por lo tanto, una distribución estacionaria de una cadena de Markov es una distribución de probabilidad que se mantiene sin cambios en la cadena a medida que avanza el tiempo.

### 1.2.5. Simulaciones

#### A. Simulación de una cadena de Markov

```
rMarkov <- function(P, n = 100, mu0 = rep(1, nrow(P))/nrow(P)) {
  # P: matriz de transición (sin valor por defecto)
  # n: número de simulaciones (100 por defecto)
  # mu0: distribución inicial (uniforme en el espacio de estados por defecto)
  # si el espacio de estados está en los nombres de las columnas de P, usarlo
  if(length(colnames(P)) == 0) estados <- 1:ncol(P) else estados <- colnames(P)
  # función de inicialización:
  func.inic <- cumsum(mu0)
  # funciones de actualización:
  func.act <- t(apply(P, 1, cumsum))
  U <- runif(n) # uniformes U1,...,Un en [0,1]
  X <- numeric(n)*NA # vector de valores simulados de la cadena, a completar
  # primer valor de la cadena
  j = 1; while(U[1] > func.inic[j]) j = j + 1;
  X[1] <- estados[j]
  # restantes valores de la cadena
  for (i in 2:n) {
    j = 1; while(U[i] > func.act[X[i - 1], j]) j = j + 1;
    X[i] <- estados[j]
  }
  X
}
```

Figura 1: Función que simula una cada de Markov.

Si consideramos un espacio de estados  $E = \{A, C, G, T\}$  (A=adenina, C=citosina, G=guanina, T=timina)

```
#sea la matriz de transición entre estados P
vector=c(.2,.25,.4,0.15,.1,.6,.1,.2,.2,.1,.35,.35,.1,.45,.2,.25)
P=matrix(vector,4,4,T)
P
```

```
0.2 0.25 0.40 0.15
0.1 0.60 0.10 0.20
0.2 0.10 0.35 0.35
0.1 0.45 0.20 0.25
```

Figura 2: Matriz de transición de la cadena de Markov.

```
X=rMarkov(P,1000)
X[1:100]
```

```
4 3 4 3 4 2 1 4 1 2 2 4 4 2 3 1 3 4 2 4 4 3 1 4 4 2 2 2 1 4 2 4 4 3 3 2 2 4 2 2 4 2 2
2 2 1 2 2 4 3 3 1 2 2 2 1 2 2 2 2 2 2 3 4 2 2 2 1 2 4 3 2 4 2 1 3 1 2 2 2 1 3 3 1 3 3 3
3 2 2 3 3 4 4 2 2 1
```

Figura 3: Probando la función *rMarkov*.

```
plot(1:100, X[1:100],type= 'b',col = 'blue',lwd = 1,las =.2, ylab= 'Estados',xlab='Tiempo',lty=10)
```

Figura 4: Graficando la cadena de Markov.




Figura 5: Grafica Tiempo VS Estados.

## Referencias

- [1] Autor, *Ttulo*, Revista/Editor, (ao)